

1 Introduction

Image-to-Image Translation은 한 도메인의 이미지를 다른 도메인의 표현으로 변환하는 비전 태스크이다. 예를 들어 흑백 이미지를 컬러로 변환하거나, 스케치를 현실적인 사진으로 바꾸는 문제 등이 이에 속한다. 이 기술은 그래픽스 및 비전 분야에서 광범위하게 응용될 수 있으나, 학습을 위해서는 원본 이미지와 변환된 이미지가 정확히 매칭된 paired 데이터가 필요하다. 하지만 현실적으로 이러한 데이터 쌍을 수집하는 일은 비용이 많이 들고, 경우에 따라서는 정답 쌍 자체가 존재하지 않기도 한다.

기존의 지도 학습 기반 방법인 Pix2pix[2]는 paired data가 주어진 상황에서 매우 높은 성능을 보이지만, 실제 응용에서는 이러한 조건을 충족하기 어렵다. 객체 변형, Style Transfer처럼 정답을 정의하기 어려운 문제에서는 특히 그러하다. 한편 CoGAN 등 비지도 학습 기반 시도들도 존재하지만, 이들 방법은 두 도메인이 공유하는 잠재 표현을 가정하거나 특정 유사도에 의존하는 등, 복잡한 도메인 간 구조적 차이를 충분히 포착하기 어렵다는 한계가 있다.

이러한 문제를 해결하기 위해 본 논문은 unpaired 환경에서도 두 도메인 (X, Y) 간의 매핑을 학습할 수 있는 CycleGAN을 제안한다. 핵심 아이디어는 $X \rightarrow Y$ 변환 이후 다시 $Y \rightarrow X$ 로 역변환했을 때 입력 이미지가 복원되도록 강제하는 cycle consistency 제약을 도입하는 것이다. 이는 adversarial loss가 수행하는 distribution matching을 보완하여, content를 유지하면서도 도메인 간 스타일 차이를 안정적으로 학습하도록 만든다. 이를 통해 데이터 수집의 제약을 획기적으로 해결하고, Mode Collapse 현상을 방지하여 안정적인 고해상도 이미지 변환을 달성하였다.

2 Methodology

본 연구의 목표는 paired training data 없이 소스 도메인 X 와 타겟 도메인 Y 사이의 매핑 함수를 학습하는 것이다. 이를 위해 본 논문은 두 개의 생성자(Generator) $G: X \rightarrow Y$ 와 $F: Y \rightarrow X$, 그리고 두 개의 판별자(Discriminator) D_X 와 D_Y 를 도입한다. 전체 모델은 Adversarial Loss를 통해 생성된 이미지의 사실성을 확보하고, Cycle Consistency Loss를 통해 원본 이미지의 내용(Content)을 보존하는 방식으로 학습된다.

2.1 Adversarial Loss

생성된 이미지가 타겟 도메인의 실제 이미지와 분포상 구별되지 않도록 만들기 위해 Adversarial Loss를 적용한다. 생성자 G 와 판별자 D_Y 에 대한 목적 함수는 다음과 같이 표현된다.

$$\mathcal{L}_{GAN}(G, D_Y, X, Y) = E_{y \sim p_{data}(y)} [\log D_Y(y)] + E_{x \sim p_{data}(x)} [\log(1 - D_Y(G(x)))]$$

여기서 G 는 D_Y 가 가짜라고 판별하지 못하도록 $G(x)$ 를 생성하여 손실을 최소화하려 하고, 반대로 D_Y 는 실제 이미지 y 와 생성된 이미지 $G(x)$ 를 정확히 구별하여 손실을 최대화하려 한다. 역방향 매핑 함수 $F: Y \rightarrow X$ 와 판별자 D_X 에 대해서도 동일한 형태의 손실 함수 $\mathcal{L}_{GAN}(F, D_X, Y, X)$ 가 적용된다.

하지만 이러한 적대적 손실만으로는 입력 x 가 타겟 도메인 Y 의 분포를 따르는 '임의의' 이미지로 매핑될 수 있어, 입력과 출력 간의 의미적 연관성을 보장할 수 없다. 이는 무수히 많은 매핑 함수가 동일한 손실 값을 가질 수 있는 제약 조건 부족(under-constrained) 문제이며, 종종 모든 입력이 동일한 출력으로 매핑되는 Mode Collapse 현상을 야기한다.

2.2 Cycle Consistency Loss

위에서 언급한 제약 조건 부족 문제를 해결하기 위해, 본 논문은 번역의 '전이성(transitivity)'에 기반한 cycle consistency constraint를 도입한다.

즉, 이미지를 변환했다가 다시 역변환했을 때 원본 이미지로 복구되어야 한다는 조건이다.

$$x \rightarrow G(x) \rightarrow F(G(x)) \approx x \quad (\text{Forward Cycle Consistency})$$

$$y \rightarrow F(y) \rightarrow G(F(y)) \approx y \quad (\text{Backward Cycle Consistency})$$

이를 위한 손실 함수 $\mathcal{L}_{cyc}(G, F)$ 는 L1 norm을 사용하여 다음과 같이 정의된다.

$$\mathcal{L}_{cyc}(G, F) = E_{x \sim p_{data}(x)} [\|F(G(x)) - x\|_1] + E_{y \sim p_{data}(y)} [\|G(F(y)) - y\|_1]$$

최종적인 전체 목적 함수는 다음과 같다. 여기서 λ 는 두 손실 간의 상대적 중요도를 조절하는 하이퍼파라미터로, 본 연구에서는 $\lambda = 10$ 으로 설정하였다.

$$\mathcal{L}(G, F, D_X, D_Y) = \mathcal{L}_{GAN}(G, D_Y, X, Y) + \mathcal{L}_{GAN}(F, D_X, Y, X) + \lambda \mathcal{L}_{cyc}(G, F)$$

2.3 Implementation Details

본 연구는 안정적인 학습과 고품질 생성을 위해 Johnson et al.의 ResNet 기반 구조를 생성자로 채택하여 깊은 네트워크에서의 정보 손실을 최소화하였으며, Batch Normalization 대신 스타일 변환에 적합한 Instance Normalization을 적용하였다. 판별자로는 70×70 PatchGAN을 사용하여 이미지의 지역적 디테일을 효과적으로 포착하도록 설계하였다. 또한 학습의 안정성을 높이기 위해 기존 GAN의 로그 우도 손실 대신 Least Squares Loss를 도입하였으며, 모델의 진동 현상을 방지하고자 최근 생성된 이미지가 아닌 이전에 생성된 50개의 이미지를 저장하는 Replay Buffer를 활용하여 판별자를 업데이트하였다.

3 Experiments

CycleGAN의 성능을 검증하기 위해 Cityscapes, Google Maps 등 다양한 데이터셋에서 실험을 수행하였다. CoGAN, BiGAN 등 기존 비지도 학습 모델들과 비교했을 때 CycleGAN은 시각적 품질과 정량적 지표 (FCN Score) 모두에서 일관되게 우수한 성능을 보였으며, 지도 학습 기반 Pix2pix에 근접한 결과를 얻어 unpaired 학습의 실용성을 입증하였다. 또한 AMT 시각 평가에서 지도↔항공사진 변환은 약 25%의 속임률(fooling rate)을 기록하여 생성 이미지의 사실성을 뒷받침하였다. 응용 실험에서도 모네 화풍 변환, 계절 변화, 사진 심도 향상 등 다양한 태스크에서 우수한 결과를 보였으며, 특히 그림을 사진으로 변환하는 경우에는 Identity Loss를 추가함으로써 색상 왜곡 문제를 효과적으로 개선하였다.

4 Conclusion & Limitations

본 연구는 cycle consistency 제약을 통해 짝지어진 데이터 없이도 두 도메인 간의 안정적인 이미지 변환이 가능함을 보였으며, 이를 통해 데이터 구축이 어려운 다양한 실제 문제에 적용 가능한 unpaired image translation 프레임워크를 제시하였다. 그러나 본 모델은 색상이나 질감 변화에는 강점을 보이지만, 개↔고양이와 같이 기하학적 구조 변화가 큰 태스크에서는 여전히 한계를 지닌다. 또한 학습 데이터 분포에 존재하지 않는 객체나 장면이 입력될 경우 변환 품질이 크게 저하될 수 있다. 향후 연구로는 이러한 기하학적 제한을 완화할 수 있는 모델 구조 개선과 약한 지도 학습(Weak Supervision)의 도입이 요구된다.

5 Reference

- [1] J.-Y. Zhu, T. Park, P. Isola, and A. A. Efros, *Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks*, Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017.

- [2] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, *Image-to-Image Translation with Conditional Adversarial Networks*, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017.
- [3] M.-Y. Liu and O. Tuzel, *Coupled Generative Adversarial Networks*, Advances in Neural Information Processing Systems (NeurIPS), 2016.