

1 Introduction

Image-to-image translation은 서로 다른 도메인 간의 시각적 표현을 보존한 채 스타일만을 변환하는 문제로, 컴퓨터 비전과 딥러닝 분야에서 꾸준히 연구되고 있다. 그러나 대부분의 기존 기법은 입력 이미지와 그에 대응하는 목표 이미지의 쌍(paired data)을 필요로 하며, 이는 실제 환경에서 구축하기 어렵거나 불가능한 경우가 많다.

CycleGAN은 이러한 한계를 해결하기 위해 제안된 모델로, 짝지어진 데이터 없이도 두 도메인 간의 변환 관계를 학습할 수 있다. 핵심 아이디어는 두 생성기와 두 판별기를 사용하여 adversarial learning을 수행하고, 변환을 두 번 적용했을 때 원본으로 복원되는 cycle consistency 제약을 추가함으로써 의미적 구조를 유지한 안정적인 매핑을 학습하는 것이다.

본 실험에서는 CycleGAN을 구현하여 MNIST(1-channel)와 SVHN(3-channel) 사이의 unpaired digit-style translation을 수행한다. 두 데이터셋은 채널 수, 색상 정보, 배경 구조가 크게 달라 변환 난이도가 높기 때문에, adversarial loss와 cycle-consistency loss가 실제 생성 결과에 어떤 영향을 미치는지 관찰하기에 적합하다. 본 보고서에서는 모델 구조, 구현 과정, 학습 결과를 분석하고, CycleGAN이 이러한 도메인 간 변환 문제에서 가지는 장점과 한계를 논의한다.

2 Theoretical Background

2.1 Generative Adversarial Networks (GANs)

Generative Adversarial Networks (GANs)는 생성 모델(Generator, G)과 판별 모델(Discriminator, D)이 서로 경쟁하며 학습하는 구조를 가진다. G 는 잠재 벡터 혹은 입력 이미지로부터 실제와 유사한 데이터를 생성하여 D 를 속이려 하고, D 는 입력된 데이터가 실제 데이터인지 G 가 생성한 가짜 데이터인지 구별하려 한다. 이 과정은 Minimax Game으로 모델링되며, 목적 함수는 다음과 같이 표현된다.

$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log (1 - D(G(z)))]$$

하지만 일반적인 GAN은 입력 데이터와 출력 데이터 간의 직접적인 대응 관계(Paired mapping)를 보장하지 못하며, 특히 Image-to-Image Translation 작업에서 입력 이미지의 고유한 콘텐츠(Content)를 유지하지 못하고 스타일만 모방하거나, 특정 출력으로만 수렴하는 Mode Collapse 문제가 발생하기 쉽다.

2.2 Cycle Consistency Loss

CycleGAN은 짝이 없는(Unpaired) 데이터셋 X 와 Y 사이의 매핑을 학습하기 위해 제안되었다. 단순히 $G: X \rightarrow Y$ 매핑만 학습할 경우, G 는 Y 도메인의 분포만 따를 뿐 입력 X 의 구조적 특징을 무시할 수 있다. 이를 해결하기 위해 CycleGAN은 역방향 매핑 $F: Y \rightarrow X$ 를 동시에 도입하고, 원본 이미지가 변환을 거쳐 다시 제자리로 돌아왔을 때 원본과 동일해야 한다는 Cycle Consistency 제약 조건을 추가한다.

Forward cycle consistency는 $x \rightarrow G(x) \rightarrow F(G(x)) \approx x$ 를, Backward cycle consistency는 $y \rightarrow F(y) \rightarrow G(F(y)) \approx y$ 를 의미한다. 이를 수식화하면 L1 norm을 사용한 Cycle Consistency Loss는 다음과 같다.

$$\mathcal{L}_{cyc}(G, F) = E_{x \sim p_{data}(x)} [\|F(G(x)) - x\|_1] + E_{y \sim p_{data}(y)} [\|G(F(y)) - y\|_1]$$

이 손실 함수는 변환된 이미지가 원본 이미지의 형태학적 정보(Shape, Semantic Structure)를 보존하도록 강제하는 결정적인 역할을 한다.

2.3 Full Objective Function

최종적으로 CycleGAN의 목적 함수는 두 개의 Adversarial Loss와 하나의 Cycle Consistency Loss의 선형 결합으로 정의된다. Adversarial Loss

는 생성된 이미지가 목표 도메인의 스타일을 따르도록 하고, Cycle Loss는 원본의 내용을 유지하도록 한다.

$$\mathcal{L}(G, F, D_X, D_Y) = \mathcal{L}_{GAN}(G, D_Y, X, Y) + \mathcal{L}_{GAN}(F, D_X, Y, X) + \lambda \mathcal{L}_{cyc}(G, F)$$

여기서 λ 는 두 손실 항 사이의 상대적 중요도를 조절하는 하이퍼파라미터이다. 본 실험에서는 λ 값을 10으로 설정하여, 서로 다른 배경과 채널 특성을 가진 MNIST와 SVHN 간의 변환 과정에서 숫자의 고유한 형태(Identity)가 소실되지 않도록 유도한다.

3 Implementation Details

3.1 Network Architecture

본 실험에서는 32×32 해상도의 이미지를 처리하기 위해 기존 CycleGAN 아키텍처를 데이터셋 특성에 맞추어 경량화하여 재설계하였다.

Generator. 생성자는 Encoder-Transformer-Decoder 구조를 기반으로 하며, 입력 이미지의 저수준 특징을 추출한 뒤 도메인 고유의 스타일을 반영한 결과를 복원하는 역할을 수행한다.

- **Encoder:** Kernel size가 각각 7과 3인 두 개의 Convolution layer로 구성되며, Strided Convolution을 통해 해상도를 32×32 에서 8×8 로 축소한다.
- **Transformer:** 3개의 Residual Block을 사용하여 깊은 표현을 학습하면서도 Skip Connection을 통해 중요한 구조적 정보(Content)를 보존하도록 하였다.
- **Decoder:** 두 개의 Transposed Convolution layer를 사용하여 축소된 feature map을 다시 원본 해상도로 복원한다. 최종 출력층에는 Tanh 활성화를 적용하여 픽셀 값을 $[-1, 1]$ 범위로 정규화하였다.
- **Activation & Normalization:** 모든 중간 레이어에는 LeakyReLU와 Batch Normalization을 적용하여 학습 안정성과 표현력의 균형을 확보하였다.

Discriminator. 판별자는 PatchGAN 구조를 채택하여 이미지 전체를 판단하는 대신 지역적 패치 단위로 Real/Fake 여부를 판별한다. 4개의 Convolution layer를 순차적으로 거쳐 8×8 크기의 출력 맵을 생성하며, 이는 각 패치의 진위 여부를 독립적으로 추정한다.

3.2 Handling Dimensionality Mismatch

본 실험의 중심 도전 과제는 MNIST(1-channel, grayscale)와 SVHN(3-channel, RGB) 간의 채널 차이에서 기인하는 Dimensionality Mismatch 문제이다. 대칭형(Symmetric) CycleGAN 구조를 그대로 적용할 경우, 1채널 입력을 3채널 필터로 처리하거나 그 반대의 경우가 발생하며, 이는 곧 Tensor Shape mismatch로 이어져 연산 자체가 불가능해진다. 따라서 두 도메인의 채널 구조에 맞추어 네트워크를 비대칭적(Asymmetric)으로 설계하는 것이 필수적이다.

- **Generator $G_{X \rightarrow Y}$:** MNIST(1-channel)을 입력으로 받아 내부 특징을 추출하고, Decoder에서 3채널(SVHN 스타일) 출력으로 변환하도록 설계하였다.
- **Generator $G_{Y \rightarrow X}$:** SVHN(3-channel)을 입력으로 받아 처리한 뒤, 최종적으로 1채널(MNIST 스타일) 출력으로 매핑하도록 구성하였다.
- **Discriminator:** D_X 는 1채널 입력을, D_Y 는 3채널 입력을 처리하도록 첫 번째 Convolution layer의 입력 채널을 독립적으로 설정하였다.

이러한 비대칭 구조는 단순한 오류 방지를 넘어, 두 도메인의 근본적 차이를 모델이 자연스럽게 학습하도록 돕는 역할도 수행한다.

3.3 Training Strategy and Hyperparameters

모델 학습은 PyTorch 프레임워크를 사용하여 NVIDIA GPU 환경에서 수행되었다. 본 실험에서 사용된 주요 하이퍼파라미터 설정은 다음과 같다.

Hyperparameter	Value
Optimizer	Adam ($\beta_1 = 0.5, \beta_2 = 0.999$)
Learning Rate	0.0002 (No scheduling)
Batch Size	64
Training Epochs	5

Table 1: Training hyperparameters used in the CycleGAN experiments.

3.3.1 Cycle Consistency Weight (λ_{cyc})

특히, 본 실험에서는 서로 다른 도메인(MNIST, SVHN) 간의 변환 과정에서 숫자의 형태(Shape)가 붕괴되는 것을 방지하는 것이 핵심 과제였다. 이를 위해 코드 상에서 Cycle Consistency Loss에 대한 가중치 λ_{cyc} 를 10.0으로 설정하였다.

$$\mathcal{L}_{Total} = \mathcal{L}_{GAN} + \lambda_{cyc} \times \mathcal{L}_{Cycle} \quad (\text{where } \lambda_{cyc} = 10.0)$$

이 설정은 생성자가 상대 도메인의 스타일을 모방하면서도 입력 이미지의 구조적 정보를 유지하도록 강제하여, 학습 초기 발생했던 이미지 뭉개짐 현상을 효과적으로 해결하였다.

4 Results & Discussion

본 실험에서는 CycleGAN을 이용하여 1채널(Grayscale)인 MNIST와 3채널(RGB)인 SVHN 데이터셋 간의 비대칭적 이미지 변환을 수행하였다. 본 절에서는 손실 곡선의 변화 양상을 정량적으로 살펴보고, 생성된 이미지를 기반으로 모델이 학습 과정에서 보여준 구조적·시각적 변화를 논의한다.

4.1 Loss Curve Analysis

학습 과정에서 Discriminator Loss는 약 1.07에서 0.7 내외로 수렴하며 판별자의 안정적인 학습을 확인할 수 있었다. 반면 Generator Loss는 점진적으로 증가하는 모습을 보였는데, 이는 판별자가 점차 강해지면서 생성자가 더 복잡한 표현을 학습해야 했기 때문이다. 이와 같은 적대적 경쟁 구조 속에서도 Cycle Consistency Loss는 0.17–0.21 범위에서 안정적으로 유지되었으며, 이는 높은 주기 일관성 가중치($\lambda_{cyc} = 10.0$)가 원본 구조 보존에 효과적으로 작용했음을 의미한다.

4.2 Qualitative Evaluation

학습 초기와 후반부의 시각적 결과를 Figure 1과 Figure 2에 제시한다. 각 figure는 MNIST → SVHN 변환과 SVHN → MNIST 복원 결과를 모두 포함한다.




Figure 1: 숫자 “7”과 “5”에 대한 MNIST → SVHN 변환 및 SVHN → MNIST 복원 결과. 위는 학습 초기 단계, 아래는 학습 후반 단계이다.




Figure 2: 숫자 “2”에 대한 MNIST → SVHN 변환 및 SVHN → MNIST 복원 결과. 위는 학습 초기 단계, 아래는 학습 후반 단계이다.

4.3 Discussion

Figure 2의 숫자 “2” 변환 결과는 양방향 변환 모두에서 구조적 형태가 안정적으로 보존된 대표적인 성공 사례이다. MNIST에서 SVHN으로의 변환에서는 SVHN 특유의 색상과 배경 질감이 자연스럽게 반영되었으며, 반대 방향 변환에서도 배경이 효과적으로 제거되고 원본의 곡선 형태가 뚜렷하게 나타났다. 이는 Cycle Consistency Loss가 구조적 특징이 명확한 숫자에 대해 강하게 작동했음을 보여준다.

한편 Figure 1의 숫자 “5” 복원 과정에서는 흥미로운 학습 패턴을 확인할 수 있었다. 학습 초기에는 비록 흐릿하지만 전체적인 윤곽이 “5”로 인식될 정도로 형태가 유지되었으나, 학습이 진행될수록 오히려 구조적 정보가 손실되며 최종 단계에서는 숫자 “1” 또는 “7”처럼 보이는 형태적 모호성이 강화되었다. 이는 SVHN의 복잡한 색상·배경 정보가 MNIST의 단순한 흑백 구조로 압축되는 과정에서 발생한 특징 손실과, CycleGAN이 구조적으로 단순한 형태로 수렴하려는 경향이 결합된 결과로 해석된다.

종합적으로, CycleGAN은 MNIST–SVHN 간의 큰 도메인 차이에도 불구하고 전반적으로 안정적인 변환 성능을 보였으며, 구조적 특징이 분명한 숫자에서는 높은 일관성을 확보하였다. 그러나 배경 대비가 낮거나 경계가 복잡한 숫자(예: SVHN의 “5”와 같은 경우)에서는 구조적 보존이 불완전할 수 있음이 확인되었다. 이러한 한계는 향후 Edge-aware Loss, Attention Mechanism, 또는 Perceptual Loss 도입을 통해 보완될 가능성이 있다.

5 Conclusion

본 실험에서는 짝이 없는(Unpaired) 데이터셋인 MNIST(1채널)와 SVHN(3채널) 간의 양방향 이미지 변환을 위해 CycleGAN을 구현하고 그 유효성을 검증하였다.

실험 결과, Cycle Consistency Loss의 가중치(λ_{cyc}) 상향 조정을 통해 초기 학습 단계에서 발생했던 구조적 붕괴(Semantic Degradation) 현상을 효과적으로 억제할 수 있었다. 이를 통해 모델은 스타일을 모방하면서도 숫자 본연의 기하학적 형태를 안정적으로 유지하였으며, 특히 구조가 명확한 객체에 대해서는 높은 수준의 양방향 변환 성능을 달성하였다.

비록 복잡한 배경을 포함한 SVHN 이미지의 일부 복원 과정에서 정보 엔트로피 차이로 인한 구조적 모호성이 관찰되었으나, 이는 도메인 간의 본질적 특성 차이에 기인한 것으로 분석된다. 결론적으로 본 연구는 비대칭 도메인 환경에서도 CycleGAN이 강력한 변환 도구를 입증하였다.

6 References

- [1] Zhu, J. Y., Park, T., Isola, P., & Efros, A. A. (2017). Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks. *Proceedings of the IEEE International Conference on Computer Vision*, 2223–2232.